

SPRAWOZDANIE

Zajęcia: Matematyka Konkretna

Prowadzący: prof. dr hab. inż. Vasyl Martsenyuk

Laboratorium Nr 2 Data 09.10.2025 Temat: "Rozkład SVD a korelacja" Wariant 15	Jakub Janik Informatyka II stopień, stacjonarne, 2 semestr, gr. CB
--	---

1. Cel ćwiczenia:

Celem ćwiczenia było zbadanie związku między rozkładem SVD macierzy obrazu a **macierzami korelacji** jego wierszy i kolumn.

Zadanie polegało na obliczeniu macierzy XX^T oraz X^TX , ich wizualizacji oraz weryfikacji zależności:

$$XX^T = U\Sigma^2U^T, \quad X^TX = V\Sigma^2V^T$$

Gdzie X to macierz obrazu, a U , Σ , V pochodzą z jego rozkładu SVD

2. Przebieg ćwiczenia:

Wprowadzenie teoretyczne:

Niech $X \in \mathbb{R}^{n \times m}$ (dla obrazu: liczba wierszy = wysokość, liczba kolumn = szerokość) Rozkład SVD:

$$X = U\Sigma V^T$$

Gdzie:

- U - ortogonalna macierz wektorów własnych macierzy XX^T
- V - ortogonalna macierz wektorów własnych macierzy X^TX
- Σ - diagonalna macierz wartości singularnych

Macierze korelacji:

Ich wartości własne są kwadratami wartości singularnych

$$XX^T = U\Sigma^2U^T, \quad X^TX = V\Sigma^2V^T$$

Metodyka:

- **Błąd rekonstrukcji** macierzy korelacji z SVD był bardzo mały (rzędu $1e-10$), co potwierdza poprawność zależności teoretycznych.
- Wartości singularne szybko maleją — większość energii obrazu zawarta jest w pierwszych kilkunastu składnikach.
- Macierz korelacji wierszy (XX^T) pokazuje podobieństwa między liniami obrazu, natomiast macierz korelacji kolumn (X^TX) – podobieństwa pionowe.

Wizualnie:

- **Macierz XX^T** często ma strukturę poziomych pasów,
- **Macierz X^TX** – pionowych pasów,
co odzwierciedla dominujące kierunki zmian intensywności w obrazie.

Kod źródłowy:

```
import numpy as np

import matplotlib.pyplot as plt
from PIL import Image
from numpy.linalg import svd
import os

# Pomocnicze konwersje
def img_as_float(img):
    arr = np.asarray(img).astype(np.float32)
    return arr / 255.0
def img_as_ubyte(img):
    arr = np.clip(img * 255.0, 0, 255).astype(np.uint8)
    return arr

# Cell 2: Wczytanie obrazu
img_path = "15.webp"
if not os.path.exists(img_path):
    raise FileNotFoundError(f"Nie znaleziono pliku: {img_path}")
img_pil = Image.open(img_path).convert('L') # skala szarości (jeden kanał)
img = img_as_float(img_pil)
plt.imshow(img, cmap='gray')
plt.title("Oryginalny obraz (15.webp)")
plt.axis('off')
plt.show()
print("Wymiary obrazu:", img.shape)

# Obliczenie SVD
U, S, VT = svd(img, full_matrices=False)
print("Kształty macierzy: U", U.shape, "S", S.shape, "VT", VT.shape)

# Macierze korelacji wierszy i kolumn
corr_rows = img @ img.T #  $XX^T$ 
corr_cols = img.T @ img #  $X^T X$ 
```

```

print("Kształt macierzy korelacji wierszy:", corr_rows.shape)
print("Kształt macierzy korelacji kolumn:", corr_cols.shape)
# Wizualizacja macierzy korelacji
fig, ax = plt.subplots(1, 2, figsize=(12, 5))
ax[0].imshow(corr_rows, cmap='viridis')
ax[0].set_title("Macierz korelacji wierszy ( $XX^T$ )")
ax[0].axis('off')
ax[1].imshow(corr_cols, cmap='viridis')
ax[1].set_title("Macierz korelacji kolumn ( $X^TX$ )")
ax[1].axis('off')
plt.show()
# Sprawdzenie własności teoretycznych
Sigma2 = np.diag(S**2)
# Odtworzenie macierzy korelacji z SVD
corr_rows_svd = U @ Sigma2 @ U.T
corr_cols_svd = VT.T @ Sigma2 @ VT
diff_rows = np.linalg.norm(corr_rows - corr_rows_svd)
diff_cols = np.linalg.norm(corr_cols - corr_cols_svd)
print(f"Błąd rekonstrukcji  $XX^T \approx U\Sigma^2U^T$ : {diff_rows:.3e}")
print(f"Błąd rekonstrukcji  $X^TX \approx V\Sigma^2V^T$ : {diff_cols:.3e}")
# Wykres wartości singularnych
plt.figure(figsize=(8,4))
plt.semilogy(S, marker='o')
plt.title("Wartości singularne obrazu (log)")
plt.xlabel("Indeks")
plt.ylabel("Wartość singularna")
plt.grid(True)
plt.show()
# Podsumowanie liczbowe energii
energy = np.cumsum(S**2) / np.sum(S**2)
k90 = np.searchsorted(energy, 0.9) + 1
print(f"Aby zachować 90% energii, wystarczy {k90} składowych SVD.")

```

Wyniki:

Oryginalny obraz (15.webp)




Wymiary obrazu: (364, 800)

Kształty macierzy: U (364, 364) S (364,) VT (364, 800)


Kształt macierzy korelacji wierszy: (364, 364)

Kształt macierzy korelacji kolumn: (800, 800)

Macierz korelacji wierszy (XX^T)




Macierz korelacji kolumn (X^TX)



Błąd rekonstrukcji $XX^T \approx U\Sigma^2U^T$: $3.993e-02$

Błąd rekonstrukcji $X^TX \approx V\Sigma^2V^T$: $3.851e-02$

Wartości singularne obrazu (log)



Aby zachować 90% energii, wystarczy 1 składowych SVD

Link do repozytorium: <https://github.com/Uczelniane/MK.git>

3. Wnioski

1. Rozkład SVD ujawnia własności korelacyjne obrazu – wektory U i V opisują odpowiednio zależności między wierszami i kolumnami.
2. Macierze XX^T i $X^T X$ są dodatnio określone i mają te same niezerowe wartości własne równe Σ^2 .
3. Szybki spadek wartości singularnych pozwala redukować wymiar danych bez dużej utraty informacji.
4. Wizualizacja macierzy korelacji dostarcza intuicji o strukturze przestrzennej obrazu – które fragmenty są podobne, a które się różnią.