

SPRAWOZDANIE

Zajęcia: Matematyka Konkretna

Prowadzący: prof. dr hab. inż. Vasyl Martsenyuk

Laboratorium Nr 1 Data 23.10.2025 Temat: "Użycie SVD do rozkładów obrazów: twarzy własne" Wariant 15	Jakub Janik Informatyka II stopień, stacjonarne, 2 semestr, gr. CB
---	---

1. Cel ćwiczenia:

Celem niniejszego sprawozdania jest praktyczne zastosowanie Rozkładu Wartości Osobliwych (SVD) w analizie obrazów, w szczególności do realizacji metody Eigenfaces (twarzy własnych). Zadanie polega na znalezieniu minimalnej liczby r twarzy własnych, która pozwala na zachowanie co najmniej $k=95\%$ informacji zawartej w zbiorze danych. Następnie, z wykorzystaniem tej zredukowanej bazy, zostanie przeprowadzona rekonstrukcja (przybliżenie) wybranego obrazu testowego.

2. Przebieg ćwiczenia:

Metodologia

Metoda Eigenfaces opiera się na analizie głównych składowych (PCA) realizowanej za pomocą rozkładu SVD macierzy danych

Przygotowanie Danych

- Wektoryzacja: Każdy obraz I_i jest przekształcany w długi wektor kolumnowy x_i
- Obliczanie Średniej: Obliczana jest "średnia twarz" $\bar{x}$ na podstawie wszystkich wektorów treningowych.
- Centrowanie: Od każdego wektora x_i odejmowana jest średnia twarz:
 $\tilde{x}_i = x_i - \bar{x}$.
- Macierz Danych: Uśrednione wektory $\tilde{x}_i$ są układane jako kolumny macierzy danych X : $X = [\tilde{x}_1, \tilde{x}_2, \dots, \tilde{x}_m]$

Rozkład SVD i PCA

Macierz X jest rozkładana na trzy macierze:

$$X = U\Sigma v^T$$

Gdzie:

- U to macierz Eigenfaces (twarzy własnych). Kolumny u_i tej macierzy reprezentują główne składowe zmienności w danych twarzy
- Σ to macierz diagonalna zawierająca wartości osobliwe σ_i
- σ_i^2 są wprost proporcjonalne do wariancji (informacji) zachowanej w danym komponencie

Wyznaczenie Minimalnej Liczby r

Liczba r jest minimalną ilością twarzy własnych (kolumn $\bar{U}$), która pozwala zachować dany procent informacji. r jest wyznaczane poprzez analizę skumulowanej sumy kwadratów wartości osobliwych:

$$\sum_{i=1}^r \sigma_i^2 > k \cdot \sum_{i=1}^d \sigma_i^2$$

Dla Wariantu 10 wymagane jest $k > 95\%$

Rekonstrukcja Obrazu

Przybliżenie obrazu testowego x_{test} odbywa się za pomocą zredukowanej macierzy Eigenfaces $\bar{U}$

$$\tilde{x}_{test} = \tilde{U}\tilde{U}^T(x_{test} - \bar{x}) + \bar{x}$$

Dane

Z uwagi na problemy z wczytaniem pliku allFaces.mat, do analizy wykorzystano publicznie dostępną bazę danych AT&T Database of Faces (Olivetti Faces) (400 obrazów, 64x64 piksele)

Wartość r

- Wymagany próg informacji: $k=95\%$
- Minimalna liczba twarzy własnych (r): 123
- Rzeczywiście zachowany procent informacji: 95.04%

Kod źródłowy:

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.linalg import svd
from sklearn.datasets import fetch_olivetti_faces
import random
K_PERCENT = 95.0
# Wczytanie bazy danych Olivetti (składa się z 400 obrazów 64x64)
try:
    # Wczytanie z targetami (numery osób)
    data = fetch_olivetti_faces(shuffle=True, random_state=42)
    images_flat = data.data
    m, d = images_flat.shape
    image_height = data.images.shape[1]
    image_width = data.images.shape[2]
    # A - macierz Piksele x Liczba Obrazów
    A = images_flat.T
    # NUMERY OSÓB (0-39) odpowiadające kolumnom w A
    person_labels = data.target
    print(f"Pomyślnie wczytano publiczną bazę danych (Olivetti/AT&T).")
    print(f"Dane: {m} obrazów o wymiarach {image_height}x{image_width}.")
except Exception as e:
    print(f"Błąd wczytywania bazy danych: {e}")
    d, m = 10000, 50
    A = np.random.rand(d, m) * 255
    image_height, image_width = 100, 100
    person_labels = np.zeros(m)
# Obliczanie "Średniej Twarzy"
mean_face = np.mean(A, axis=1)
# Odjęcie "Średniej Twarzy" od każdego obrazu
X = A - mean_face[:, np.newaxis]
# Wybór obrazu testowego i określenie źródła
test_index = random.randint(0, m - 1)
x_test = A[:, test_index]
x_test_mean_subtracted = x_test - mean_face
# OKREŚLENIE ŹRÓDŁA OBRAZU TESTOWEGO
person_id = person_labels[test_index]
# Olivetti ma 10 zdjęć na osobę. Obliczamy numer zdjęcia dla danej osoby.
image_num_for_person = np.sum(person_labels[:test_index] == person_id) + 1
# SVD, Analiza i Znalezienie min
U, S, Vh = svd(X, full_matrices=False)
singular_values_sq = S**2
total_variance = np.sum(singular_values_sq)
cumulative_percentage = (np.cumsum(singular_values_sq) / total_variance) * 100

r_index = np.where(cumulative_percentage > K_PERCENT)[0]
r_min = r_index[0] + 1 if r_index.size > 0 else len(S)
zachowany_procent = cumulative_percentage[r_min - 1]
```

```

print(f"Obraz testowy: Osoba ID {person_id}, Zdjęcie nr {image_num_for_person}
(Indexs w macierzy: {test_index})")
print(f"Minimalna liczba 'eigenfaces' (r): {r_min}")
print(f"Zachowany procent informacji z r={r_min}: {zachowany_procent:.2f}%")
# Rekonstrukcja Obrazu Testowego
U_tilde = U[:, :r_min]
x_test_approx_mean_subtracted = U_tilde @ (U_tilde.T @ x_test_mean_subtracted)
x_test_approx = x_test_approx_mean_subtracted + mean_face
# Wizualizacja Wyników z Źródłem
image_orig_resized = x_test.reshape(image_height, image_width)
image_approx_resized = x_test_approx.reshape(image_height, image_width)
fig, axes = plt.subplots(1, 3, figsize=(15, 5))
fig.suptitle(
    f"Rekonstrukcja Twarzy (Źródło: Osoba {person_id}, Zdjęcie {im-
age_num_for_person}) | r={r_min}, Zachowano {zachowany_procent:.2f}%",
    fontsize=14
)
# Średnia Twarz
axes[0].imshow(mean_face.reshape(image_height, image_width), cmap='gray')
axes[0].set_title('Średnia Twarz (Zbiór Treningowy)')
axes[0].axis('off')
# Oryginalny Obraz Testowy
axes[1].imshow(image_orig_resized, cmap='gray')
axes[1].set_title(f'Oryginalny Obraz Testowy')
axes[1].axis('off')
# Zrekonstruowany Obraz
axes[2].imshow(image_approx_resized, cmap='gray')
axes[2].set_title(f'Rekonstrukcja (r={r_min} Eigenfaces)')
axes[2].axis('off')
plt.show()
# Wykres skumulowanej wariancji
plt.figure(figsize=(8, 4))
plt.plot(range(1, len(cumulative_percentage) + 1), cumulative_percentage,
marker='.', linestyle='-')
plt.axhline(y=K_PERCENT, color='r', linestyle='--', label=f'{K_PERCENT:.0f}%
Wymagane')
plt.axvline(x=r_min, color='g', linestyle='--', label=f'r = {r_min}')
plt.xlabel('Liczba Eigenfaces (r)')
plt.ylabel('Skumulowany Zachowany Procent Informacji (%)')
plt.title('Analiza Zachowanej Informacji (PCA/SVD)')
plt.legend()
plt.grid(True)
plt.show()

```

Wyniki:

Pomyślnie wczytano publiczną bazę danych (Olivetti/AT&T).


Dane: 400 obrazów o wymiarach 64x64.

Obraz testowy: Osoba ID 23, Zdjęcie nr 1 (Indeks w macierzy: 18)

Minimalna liczba 'eigenfaces' (r): 123

Zachowany procent informacji z $r=123$: 95.04%

Rekonstrukcja Twarzy (Źródło: Osoba 23, Zdjęcie 1) | $r=123$, Zachowano 95.04%



Link do repozytorium: <https://github.com/Uczelniane/MK.git>

3. Wnioski

Analiza SVD pozwoliła na skuteczną redukcję wymiarowości macierzy twarzy, co jest istotą metody Eigenfaces. Dla osiągnięcia wymaganego poziomu zachowanej informacji ($k=95\%$) konieczne było wykorzystanie $r=123$ twarzy własnych

Zrekonstruowany obraz jest wizualnie bardzo zbliżony do oryginalnego, co potwierdza, że zdecydowana większość informacji wizualnej o twarzy jest zawarta już w pierwszych (najważniejszych) r wektorach własnych