

SPRAWOZDANIE

Zajęcia: Matematyka Konkretna

Prowadzący: prof. dr hab. inż. Vasyl Martsenyuk

Laboratorium Nr 1 Data 30.10.2025 Temat: "Rozkład SVD a korelacja" Wariant 15	Jakub Janik Informatyka II stopień, stacjonarne, 2 semestr, gr. CB
--	---

1. Cel ćwiczenia:

Celem zadania było teoretyczne i praktyczne zbadanie funkcji aktywacji **ELU**. Obejmowało to:

1. Zaimplementowanie funkcji ELU oraz jej gradientu w języku
2. Graficzną wizualizację obu krzywych na wspólnym wykresie

2. Przebieg ćwiczenia:

Wprowadzenie:

Funkcja ELU jest ciągłą modyfikacją funkcji ReLU, która umożliwia uzyskanie ujemnych wartości wyjściowych. Jest zdefiniowana wzorem:

$$f(x) = \begin{cases} x & \text{dla } x > 0 \\ \alpha(e^x - 1) & \text{dla } x \leq 0 \end{cases}$$

gdzie α (alfa) jest hiperparametrem kontrolującym nasycenie dla ujemnych wejść (w badaniu przyjęto $\alpha=1.0$)

Gradient Funkcji ELU

Gradient funkcji jest niezbędny do procesu uczenia sieci neuronowej metodą wstecznej propagacji błędów (backpropagation) i jest zdefiniowany wzorem:

$$f'(x) = \begin{cases} 1 & \text{dla } x > 0 \\ \alpha e^x & \text{dla } x \leq 0 \end{cases}$$

Metoda Badawcza

Badanie zostało przeprowadzone w środowisku Python z wykorzystaniem bibliotek NumPy oraz Matplotlib. Poniżej przedstawiono zwięzły kod, który zaimplementował funkcję i jej pochodną, a następnie wygenerował wykres

Kod źródłowy:

```
import numpy as np
import matplotlib.pyplot as plt

alpha = 1.0

def elu_function(x):

    return np.where(x > 0, x, alpha * (np.exp(x) - 1))

def elu_gradient(x):

    return np.where(x > 0, 1, alpha * np.exp(x))

# Generowanie danych wejściowych (zakres x)
x_values = np.linspace(-5, 5, 200)

# Obliczanie wartości funkcji ELU i jej gradientu
elu_y = elu_function(x_values)
elu_grad = elu_gradient(x_values)


plt.figure(figsize=(10, 6))

# Wyświetlanie funkcji ELU
plt.plot(x_values, elu_y, label='Funkcja ELU ($f(x)$)', color='blue', linewidth=2)

# Wyświetlanie gradientu funkcji ELU
plt.plot(x_values, elu_grad, label='Gradient ELU ($f\'(x)$)', color='red', linestyle='--', linewidth=2)

plt.title('Funkcja Aktywacji ELU i jej Gradient ($\\alpha=\\{\\}$)'
          .format(alpha), fontsize=14)
plt.xlabel('Wartość wejściowa ($x$)', fontsize=12)
plt.ylabel('Wartość Funkcji / Gradientu', fontsize=12)
plt.grid(True, linestyle=':', alpha=0.7)
plt.axhline(0, color='black', linewidth=0.7)
plt.axvline(0, color='black', linewidth=0.7)
plt.legend(fontsize=11)
plt.ylim(-2, 3)
plt.show()
```

Wyniki:



Analiza Wykresu:

- Funkcja ELU (linia ciągła): Dla dodatnich wartości wejściowych ($x > 0$) funkcja zachowuje się liniowo ($y=x$). Dla ujemnych wartości ($x \leq 0$) funkcja przyjmuje wartości ujemne, asymptotycznie dążąc do -1.0 (dla $\alpha=1$).
- Gradient ELU (linia przerywana): Dla $x > 0$ gradient jest stały i wynosi 1. Dla $x \leq 0$ gradient jest niezerowy, ale gwałtownie maleje w kierunku zera (αe^x), co jest kluczowe dla procesu uczenia.

Link do repozytorium: <https://github.com/Uczelniane/MK.git>

3. Wnioski

Funkcja ELU jest ceniona w głębokim uczeniu maszynowym ze względu na dwie kluczowe zalety w porównaniu do powszechnie używanej funkcji ReLU:

- Eliminacja Problemu "Martwych Neuronów":
 - Utrzymanie niezerowego gradientu dla ujemnych wejść ($f'(x)=\alpha e^x$) zapobiega trwałemu wyłączeniu się neuronów, co zwiększa stabilność i efektywność uczenia, szczególnie w głębokich architekturach.
- Szybsza Konwergencja dzięki Ujemnym Wartościom Wyjściowym:
 - Generowanie ujemnych aktywacji umożliwia przesunięcie średniej aktywacji sieci w kierunku zera

- Właściwość ta sprzyja lepszemu uogólnieniu i przyspiesza konwergencję algorytmu spadku gradientu, co przekłada się na krótszy czas treningu modelu